

Project

Γενετικοί αλγόριθμοι

Με το project αυτό θα ασχοληθούμε με την σχεδίαση ενός γενετικού αλγορίθμου για την εύρεση της αναλυτικής έκφρασης της f , όπου η f είναι μια άγνωστη αλλά συνεχής συνάρτηση 2 μεταβλητών u_1, u_2 . Για τον προσδιορισμό της αναλυτικής έκφρασης θα χρησιμοποιηθούν 15 Gaussians συναρτήσεις της μορφής

$$G(u_1, u_2) = Ae^{-\left(\frac{(u_1 - c_1)^2}{2\sigma_1^2} + \frac{(u_2 - c_2)^2}{2\sigma_2^2}\right)}.$$

Για την διαδικασία της παραγωγής δεδομένων εισόδου-εξόδου θα χρησιμοποιηθεί η συνάρτηση:

$$f(u_1, u_2) = \sin(u_1, u_2) \sin(u_2^2) \quad \text{όπου } u_1 \in [-1, 2] \quad \text{και } u_2 \in [-2, 1]$$

- **Γενετικοί αλγόριθμοι**

Οι Γενετικοί αλγόριθμοι ανήκουν στο κλάδο της επιστήμης υπολογιστών και αποτελούν μια μέθοδο αναζήτησης βέλτιστων λύσεων σε συστήματα που μπορούν να περιγραφούν ως μαθηματικό πρόβλημα. Είναι χρήσιμοι σε προβλήματα που περιέχουν πολλές παραμέτρους/διαστάσεις και δεν υπάρχει αναλυτική μέθοδος που να μπορεί να βρει το βέλτιστο συνδυασμό τιμών για τις μεταβλητές ώστε το υπό εξέταση σύστημα να αντιδρά με όσο το δυνατόν με το επιθυμητό τρόπο. Ο τρόπος λειτουργίας των Γενετικών Αλγορίθμων είναι εμπνευσμένος από τη βιολογία. Χρησιμοποιεί την ιδέα της εξέλιξης μέσω γενετικής μετάλλαξης, φυσικής επιλογής και διασταύρωσης. Όπως οι οργανισμοί έτσι και οι λύσεις ενός προβλήματος, μέσα από την εφαρμογή γενετικών τελεστών, μεταβιβάζουν χαρακτηριστικά από γενιά σε γενιά, οδηγώντας σταδιακά στην εξαφάνιση κακών λύσεων και στη βελτίωση καλών λύσεων. Οι Γενετικοί Αλγόριθμοι

διατηρούν έναν πληθυσμό πιθανών λύσεων, του προβλήματος που μας ενδιαφέρει, πάνω στον οποίο δουλεύουν, σε αντίθεση με άλλες μεθόδους αναζήτησης που επεξεργάζονται ένα μόνο σημείο του διαστήματος αναζήτησης. Έτσι ένας Γενετικός Αλγόριθμος πραγματοποιεί αναζήτηση σε πολλές κατευθύνσεις και υποστηρίζει καταγραφή και ανταλλαγή πληροφοριών μεταξύ αυτών των κατευθύνσεων. Ο πληθυσμός υφίσταται μια προσομοιωμένη γενετική εξέλιξη χρησιμοποιώντας διάφορους γενετικούς τελεστές όπως η επιλογή, η διασταύρωση και η μετάλλαξη. Στην πράξη ο αλγόριθμος ξεκινά μ' ένα σύνολο λύσεων - ονομάζονται γονιδιώματα, δανειζόμενες το όνομά τους από τη βιολογία - οι οποίες συνιστούν τον "πληθυσμό". Κατόπιν ζητείται από τον υπολογιστή να δημιουργήσει μια σειρά τυχαίων ανασυνδυασμών και μεταλλάξεων των "γονιδιωμάτων". Οι πιο ικανές λύσεις για ένα συγκεκριμένο πρόβλημα συνεχίζουν να εξελίσσονται και ανασυνδυάζονται τυχαία, μέχρις ότου "επιβιώσουν" οι καλύτερες.

Παρακάτω περιγράφονται αναλυτικά οι διάφοροι γενετικοί τελεστές και οι διάφορες συναρτήσεις που χρησιμοποιήθηκαν για τον σχεδιασμό του γενετικού αλγορίθμου.

- **Κωδικοποίηση γονιδίων**

Η κωδικοποίηση των γονιδίων στους γενετικούς αλγορίθμους γίνεται συνήθως με την χρήση του δυαδικού συστήματος αρίθμησης 0 και 1. Στην περίπτωση μας όμως έγινε χρήση πραγματικών αριθμών οι οποίοι βασίζονται στο ότι τα χρωμοσώματα αποτελούνται πλάτος, κέντρο και τυπική απόκλιση. Συγκεκριμένα:

- ~ Πλάτος: $A \in (f_{min}, f_{max})$ όπου f_{min}, f_{max} η ελάχιστη και η μέγιστη τιμή της συνάρτησης μας αντίστοιχα δηλαδή $A \in (-0.9996, 0.8415)$
- ~ Κέντρα: c_1, c_2 με πεδία ορισμού $c_1 \in (-4, 5)$, $c_2 \in (-5, 4)$,
- ~ Τυπική απόκλιση: $\sigma_1, \sigma_2 \in (0.3, 1.1)$

- **Συνάρτηση test_f.m**

Η συνάρτηση test_f επιστρέφει την τιμή της συνάρτησης $f(u_1, u_2) = \sin(u_1, u_2) \sin(u_2^2)$ με ορίσματα u_1, u_2 .

- **Συνάρτηση limits.m**

Η συνάρτηση limits υπολογίζει την μέγιστη και την ελάχιστη τιμή της συνάρτησης f δύο παραμέτρων. Φτιάχνει ένα πλαίσιο 100x100 μεταξύ των ορίων $u_1 \in [-1, 2]$ και $u_2 \in [-2, 1]$ και υπολογίζει τις τιμές της f σε όλα τα σημεία. Επιστρέφει στο τέλος την μικρότερη και μεγαλύτερη τιμή από αυτές που υπολόγισε.

- **Συνάρτηση *f_approx.m***

Η συνάρτηση *f_approx* υπολογίζει την προσέγγιση μιας δεδομένης συνάρτησης στις καθορισμένες συντεταγμένες εισόδου χρησιμοποιώντας έναν γραμμικό συνδυασμό Gaussians συναρτήσεων που αντιπροσωπεύονται από τις παραμέτρους στο διάνυσμα γονιδίων. Αρχικά η προσέγγιση της συνάρτησης θα γίνονταν με Gaussians συναρτήσεις της μορφής

$$G(u_1, u_2) = e^{-\left(\frac{(u_1 - c_1)^2}{2\sigma_1^2} + \frac{(u_2 - c_2)^2}{2\sigma_2^2}\right)}$$

Από την τρισδιάστατη όμως αναπαράσταση την δοθείσας συνάρτησης για την παραγωγή δεδομένων φαίνεται πως η συνάρτηση παίρνει και αρνητικές τιμές. Για τον λόγο αυτόν εισαγάγαμε τον τελεστή *A* και έτσι οι Gaussians είναι της μορφής

$$G(u_1, u_2) = Ae^{-\left(\frac{(u_1 - c_1)^2}{2\sigma_1^2} + \frac{(u_2 - c_2)^2}{2\sigma_2^2}\right)}$$

- **Συνάρτηση *fitness.m***

Η συνάρτηση *fitness.m* δηλαδή η συνάρτηση ικανότητας δίνει το μέτρο ικανότητας της λύσης. Σύμφωνα με την συνάρτηση ικανότητας, οι λύσεις που βρίσκονται πιο κοντά στην επιθυμητή σε σχέση με τις άλλες είναι αυτές που αναπαράγονται στην επόμενη γενιά και λαμβάνουν μια τυχαία μετάλλαξη. Επαναλαμβάνοντας αυτή τη διαδικασία για αρκετές γενιές, το επιθυμητό αποτέλεσμα θα παράγουν ένα γονίδιο/λύση που θα περιέχει τις τιμές για τις παραμέτρους που ικανοποιούν όσο καλύτερα γίνεται την Σ.Ι. Ως Σ.Ι. χρησιμοποιήθηκε το μέσο τετραγωνικό σφάλμα (mean squared error) κατά το οποίο για πραγματική τιμή της συνάρτησης $f(x_i)$ τότε η προσέγγιση $\overline{f(x_i)}$ είναι $e_{mse} = \left(\frac{1}{n}\right) * \sum (f(x_i) - \overline{f(x_i)})^2$ με *n* ο αριθμός των σημείων της προσέγγισης. Η συνάρτηση *fitness.m* επιστρέφει το μέσο τετραγωνικό σφάλμα.

- **Συνάρτηση *crossover.m***

Η διαδικασία της διασταύρωσης (crossover) συνδυάζει τις γενετικές πληροφορίες δυο ατόμων του πληθυσμού που ονομάζονται γονείς και παράγονται απόγονοι. Η διασταύρωση μπορεί να γίνει με διάφορους τρόπους. Στην συγκεκριμένη περίπτωση επιλέχθηκε η χρήση της μέσης τιμής των αντίστοιχων στοιχείων δυο γονέων δημιουργώντας με τον τρόπο αυτό ένα απόγονο. Η διασταύρωση πραγματοποιείται σε όλα τα άτομα του νέου πληθυσμού που ορίζεται στη συνέχεια.

- **Συνάρτηση *mutation.m***

Η συνάρτηση της μετάλλαξης εισάγει μικρές τυχαίες αλλαγές στο γενετικό υλικό ενός ατόμου. Για να είναι τυχαία η αλλαγή, διαλέγουμε τυχαία έναν αριθμό και χρησιμοποιούμε την συνάρτηση `mod` του τυχαίου αριθμού με το 5 έτσι ώστε να αλλάξουμε έναν από τις 5 παραμέτρους του χρωμοσώματος (πλάτος, κέντρα, τυπικές αποκλίσεις). Για την διαδικασία χρησιμοποιούμε μια πιθανότητα μετάλλαξης.

- **Συνάρτηση *random_section.m***

Η συνάρτηση `random_section.m` διαλέγει τυχαία ένα πλήθος ατόμων από τον πληθυσμό για να χρησιμοποιηθεί στην συνάρτηση `crossover`.

- **Συνάρτηση *roulette_wheel_selection.m***

Η συνάρτηση `roulette_wheel_selection` υπολογίζει τις πιθανότητες επιλογής κάθε ατόμου βασισμένη στη συνάρτηση ικανότητας του. Η πιθανότητα για κάθε άτομο είναι ανάλογη με την ικανότητα του σε σχέση με τη συνολική ικανότητα του πληθυσμού. Συγκεκριμένα υπολογίζονται οι αθροιστικές πιθανότητες αθροίζοντας τον πίνακα πιθανοτήτων. Διαλέγονται άτομα και για κάθε επιλογή, δημιουργείται μια τυχαία τιμή και κάθε άτομο που η αθροιστική πιθανότητα του είναι μεγαλύτερη της τυχαία τιμής τότε επιλέγεται.

- **Συνάρτηση *genetic_algorithm.m***

Όλες οι παραπάνω συναρτήσεις χρησιμοποιούνται στην υλοποίηση του `genetic_algorithm.m`.

Αρχικά υπολογίζεται το μέγεθος `eliteSize` το οποίο αντιπροσωπεύει το πλήθος που θα θεωρήσουμε πως έχει πολύ καλό `fitness value`. Αυτό γίνεται πολλαπλασιάζοντας και στρογγυλοποιώντας τον συνολικό πληθυσμό με το `elite percentage`. Το ίδιο συμβαίνει και με το `diversitySize` το οποίο αντιπροσωπεύει το ποσοστό του πληθυσμού το οποίο θα διαλεχθεί τυχαία. Ο πληθυσμός αρχικοποιείται με τυχαίες τιμές που βρίσκονται μέσα στα όρια που ορίσαμε παραπάνω για τα χρωμοσώματα.



Ξεκινάει έτσι ο επαναληπτικός βρόγχος `for` που τρέχει για τον αριθμό των γενιών που θα ορίσουμε στη `main`. Μέσα στον βρόχο υπολογίζεται ο πίνακας `fitness_array` που περιλαμβάνει τις τιμές της συνάρτησης `fitness` για όλα τα άτομα του πληθυσμού και στη συνέχεια ταξινομούνται και κατατάσσονται τα άτομα στον πληθυσμό σε αυξάνοντα πληθυσμό. Καθορίζεται ο πληθυσμός `elite` που περιλαμβάνει `eliteSize` άτομα με τις καλύτερες τιμές ικανότητας και ο πληθυσμός που θα χρησιμοποιηθεί στην συνάρτηση `roulette` ο οποίος είναι ο συνολικός πληθυσμός εκτός των τυχαίων ατόμων και των καλύτερων. Καλείται έτσι η





συνάρτηση και δημιουργείται ένα νέο πλήθος rouletteSelection. Καταλήγουμε έτσι να έχουμε έναν νέο πληθυσμό που αποτελείται από τα elitePopulation, rouletteSelection, diversityPopulation. Για τον νέο αυτόν πληθυσμό καλείται η random section για τα αποτελέσματα του οποίου γίνεται το crossover.

Μετά το crossover γίνεται το mutation, ανανεώνεται ο πληθυσμός στον νέο πληθυσμό για την επόμενη γενιά και ξαναυπολογίζεται ο πίνακας fitness μετά την διασταύρωση και την μετάλλαξη.

Προσέγγιση Συνάρτησης




Για την επιλογή της πιθανότητας mutation ο αλγόριθμος έτρεξε 1000 επαναλήψεις, με χρήση 15 Gaussians. Επειδή κάθε φορά που τρέχει ο αλγόριθμος έχουμε διαφορετικά διαγράμματα εξαιτίας της τυχαιότητας του πληθυσμού που επιλέγεται, ο αλγόριθμος εκτελέστηκε από 10 φορές για κάθε περίπτωση και τα αποτελέσματα που φαίνονται στα παρακάτω διαγράμματα αποτελούν τον μέσο όρο αυτών.








Παρατηρούμε πως ένα καλό ποσοστό μετάλλαξης που προσφέρει αρκετά χαμηλό σφάλμα είναι σε μια ενδιάμεση τιμή όπως το 0.05 (5%). Για χαμηλότερες τιμές το σφάλμα εμφανίζεται μεγαλύτερο. Το ίδιο συμβαίνει και αυξάνοντας το ποσοστό μετάλλαξης σε μεγαλύτερες τιμές όπως στο 0.1 (10%).

Με σταθερό το ποσοστό μετάλλαξης στο 0.05 μπορούμε να δούμε την επίδραση του πλήθους των Gaussians. Το σφάλμα αυξάνεται όσο λιγότερες Gaussians έχουμε. Για τον λόγο αυτό επιλέγουμε να χρησιμοποιήσουμε το μέγιστο πλήθος διαθέσιμων Gaussians (15).






Error of the approximation in 2D for 15 Gaussians

Διατηρώντας το ποσοστό μετάλλαξης στο 0.05 και χρησιμοποιώντας 15 Gaussians ελέγχουμε την επίδραση του ποσοστού με τις καλύτερες τιμές fitness function. Παρατηρούμε πως το μικρότερο σφάλμα το έχουμε για elite percentage = 30%



Error of the approximation for elite percentage = 0.3


Όμοια για σταθερές όλες τις προηγούμενες παραμέτρους μπορούμε να παρατηρήσουμε πως μια καλή τιμή για το ποσοστό diversity είναι το 60%.




Error of the approximation for diversity percentage = 0.6

Έχοντας προσδιορίσει όλες τις παραμέτρους που χρειαζόμασταν μπορούμε να προχωρήσουμε στον αλγόριθμο μας.

Η πραγματική μορφή της f παρουσιάζεται παρακάτω:





Εκτελώντας τον αλγόριθμο για 10000 επαναλήψεις για τα ποσοστά που επιλέξαμε έχουμε την εξής προσέγγιση της συνάρτησης f :



Παρατηρούμε πως η προσέγγιση της f πλησιάζει πολύ την πραγματική συνάρτηση.

Το σφάλμα προσέγγισης είναι 0.0075 που είναι πολύ κοντά στο 0 άρα έχουμε μια αρκετά καλή προσέγγιση. Η γραφική του σφάλματος σε 2D και 3D φαίνεται στα παρακάτω διαγράμματα:



Παρατηρήσαμε πως για μεγαλύτερο μέγεθος πληθυσμού (10000 αντί για 1000) έχουμε μικρότερο σφάλμα και καλύτερη προσέγγιση.

Στον παρακάτω πίνακα παρουσιάζονται οι τιμές των 15 Gaussians για τον καλύτερο πληθυσμό που βρήκαμε παραπάνω.

Gaussian					
Number	A	Center 1	Center 2	$\sigma 1$	$\sigma 2$
1^η	0.53586	-0.2932	-0.32283	0.92925	0.45906
2^η	-1.4769	0.071586	-1.099	0.8458	0.44627
3^η	-0.20232	-0.91491	-0.70508	0.70793	0.71754
4^η	0.78696	0.16288	-1.738	1.0828	0.94757
5^η	0.17918	-0.27654	1.0413	0.36865	0.40587
6^η	0.10996	-0.84394	0.18597	0.36593	0.45293
7^η	-0.31471	-0.38597	-0.9346	1.031	0.57878
8^η	-0.31793	-0.41746	0.47391	0.89687	0.48373
9^η	-0.31527	-0.43644	-0.75252	0.95911	0.67803
10^η	-0.41993	0.89915	-0.80831	0.50627	0.63502
11^η	0.68942	0.52196	1.0134	0.8067	0.32553
12^η	1.1032	0.7717	-0.86008	1.0857	0.30992
13^η	0.1358	-0.021426	-0.08116	0.97313	0.54894
14^η	-0.18328	-0.15872	-0.68876	0.94845	0.69354
15^η	0.2012	1.0036	0.90014	0.85059	0.4627